

Fouille de Données

Processus ECD, fouille de motifs, clustering

Motivations

- Développement des TICs

- Gestion et collection de très grands volumes de données




Quelles sont
les fraudes ?



Associations entre
produits?



Quel type
d'étoile?



Relations entre
gènes?

Motivations


- Développement des TICs
 - Gestion et collection de très grands volumes de données



Quelles sont
les fraudes ?



De telles analyses sont impossibles manuellement !!!



Relations entre gènes?

Motivations


- Développement des TICs

- Gestion et collection de très grands volumes de données




Quelles sont
les fraudes ?

Merci Fouille
de données !!!



De telles
analyses sont
impossibles
manuellement !!!



Relations entre
gènes?




Evolution des sciences

- Avant 1600 : science empirique
- 1600-1950 : science théorique
- Années 50 - Années 90 : «Computational science»
 - Depuis plus de 50 ans, beaucoup de disciplines se sont développées sur une 3ème branche - le calcul - comme en physique,
 - Simulation : trouver des modèles proches de la réalité
- 1990 - Aujourd'hui : «data science»
 - Données omniprésentes (nouveaux instruments, simulations)
 - capacité à gérer et stocker des volumes gigantesques.
 - Internet
 - **La fouille de données est devenu un challenge majeur !!!**

Knowlege Discovery from Database (KDD)

- KDD (Extraction de Connaissances à partir des Données) est un processus (semi)- automatique d'extraction de connaissances à partir de bases de données où les connaissances sont :
 - valides
 - non connues a priori
 - potentiellement utiles [Fayad et al., 96]
- Remarques :
 - semi-automatique : différent d'une analyse manuelle mais souvent une interaction avec un utilisateur est nécessaire
 - non connues a priori : pas des tautologies.
 - potentiellement utiles : pour une application donnée

Le processus KDD



Processus itératif et interactif

«Focussing»

- Comprendre l'application
 - Ex. : Etablir une nouvelle tarification.
- Définir l'objectif KDD
 - Ex. : Etablir des «profils de consommateurs»
- Acquisition des données
 - Ex. : Bases de données des factures
- Gestion des données
 - Système de fichiers ou SGBD ?
- Sélection des données pertinentes
 - Ex. : considérer les 100 000 clients les plus importants et tous leurs appels sur l'année 2009



Exemple
d'application

Pré-traitement

- Intégration des données à partir de différentes sources
 - Conversion des noms d'attributs (CNo -> CustomerNumber)
 - Utilisation de la connaissance du domaine pour détecter les doublons (e.g., utiliser les codes postaux)
- Vérifier la cohérence des données :
 - des contraintes spécifiques à l'application
 - Résolution des incohérences
- «Completion»
 - Le cas des valeurs manquantes
- **Le pré-traitement des données est souvent la tâche la plus coûteuse dans le processus KDD!**

Pré-traitement

- Entrepôts de données
 - persistant
 - Intégration de données issues de plusieurs sources
 - Dans un but d'analyse ou de prise de décision




figure provenant de M. Ester

Transformation


- Discrétisation des attributs numériques
 - Indépendamment de la tâche de fouille de données
 - Ex. : partitionner le domaine des attributs en des intervalles de même longueur.
 - Spécifique de la tâche de fouille de données
 - Partitionner en des intervalles qui maximisent le gain d'information par rapport à la classe
- Génération d'attributs dérivés :
 - Agrégation d'un ensemble d'attributs
 - Ex. : à partir d'appels
 - nb minutes par jour, semaine, appels locaux ...
 - Combinaison d'attributs :
 - Ex. : variation de revenu (revenu 2009 - revenu 2008)

Transformation

- Sélection des attributs
 - manuellement : Si les connaissances du domaine sont disponibles pour les attributs.
 - de façon automatique :
- Trop d'attributs -> des répercussions sur l'étape de fouille de données
- Choix des attributs primordial :
 - Ex. : glace à la fraise

Data Mining

- Définition [Fayad et al. 96]
 - La fouille de données est l'application d'algorithmes efficaces qui identifient les motifs contenus dans une base de données
- Les différentes tâches de fouille :



- Autres tâches : regression, détection d'outlier, etc.

Data Mining

- Applications
 - Clustering
 - Segmentation, structuration d'un ensemble de documents «web», déterminer des familles de protéines et des «super-familles», découvertes de communautés
 - Classification :
 - prédiction de la fonction d'une protéine, accorder un crédit, interpréter des images en astronomie, etc.
 - Règles d'association :
 - mise en rayon, promotion, améliorer la structure d'un site web ...


Evaluation

- Présentation des motifs découverts avec une visualisation appropriée
- Evaluation des motifs par l'utilisateur
- Si l'évaluation n'est pas satisfaisante, alors relancer la fouille avec :
 - des paramètres différents
 - d'autres méthodes
 - d'autres données
- Si l'évaluation est positive :
 - Intégrer les connaissances découvertes dans une base de connaissance
 - Utiliser ces connaissances dans les futures processus KDD

Evaluation

- Intérêt des motifs découverts :
 - motifs déjà connus ?
 - motifs surprenants ?
 - motifs pertinents par rapport à l'application ?
- Pouvoir prédictif
 - Quel est la précision du motif ?
 - Dans combien de cas se produit il ?
 - Peut-il se généraliser à d'autres cas non couverts ?

Données, information, connaissance




Data Mining ou non ?

- Recherche le salaire l'employé Dupont
- Interroger un moteur de recherche pour avoir des informations sur le data mining
- Regrouper un ensemble de documents retourner par un moteur de recherche en fonction de leur contenu
- Les personnes qui réalise l'action A réalise dans le mois qui suit l'action B

Applications KDD : Astronomie

- SKICAT System [Fayad et al 1996]

- Architecture



- Méthode de classification : arbre de décision

- Evaluation :

- beaucoup plus rapide qu'une classification manuelle
- Classifie aussi des objets célestes très petits

Applications KDD : Marketing

- Customer segmentation [Piatetsky-Shapiro et al 2000]
- But : partitionner les consommateurs par rapport à leurs achats
- Motivation :
 - product packages
 - établir une nouvelle politique tarifaire

Applications KDD : Commerce électronique

Produits fréquemment achetés ensemble



Prix éditeur : EUR 63,00
Prix pour les trois: EUR 51,22

[Ajouter ces trois articles au panier](#)

[Afficher la disponibilité du produit et le mode de livraison](#)


- Cet article : Le Symbole perdu de Dan Brown
- La première nuit de Marc Levy
- L'Echappée belle de Anna Gavalda

Les clients ayant acheté cet article ont également acheté

Page 1 sur 17



[Le symbole retrouvé : Dan Brown et le mystère... de Eric Giacometti](#)
 (1)
EUR 15,11



[La première nuit de Marc Levy](#)
 (22)
EUR 19,95



[Le Symbole Perdu Décodé de Alain Bauer](#)
EUR 15,20



[La forêt des Mânes de Jean-Christophe Grangé](#)
 (49)
EUR 21,75




[Le miroir de Cassandre de Bernard Werber](#)
 (20)
EUR 21,75




[La stratégie Bancroft de Robert Ludlum](#)
 (2)
EUR 19,86




Applications KDD : puces ADN



Le data mining au centre du processus KDD



Data mining : à la confluence de nombreuses disciplines




Plan du cours

- Fouille de motifs (MP)
 - Règle d'association, algorithme Apriori
 - Fouille de séquences
 - Fouille sous contraintes
 - Autres types de motifs et données
- Clustering (MP)
- Apprentissage supervisé (AA)

Motifs ensemblistes et règles d'association

Introduction

Motivations : chercher des régularités dans les données



Base de données de transactions

beurre, lait, vin

oeufs, farine, coca

....

couches, bières, lait


- Analyse du «panier de la ménagère»
- Quels sont les produits qui sont fréquemment achetés ensemble ?
- Applications : rayonnage, mailing, cross marketing ...

Règles d'association

- Forme :
 - Corps -> Tête [support, confiance]
- Exemples :
 - couches -> bières [0.5, 0.7]
 - 98% des personnes qui achètent des pneus, prennent l'option montage.



Achat
des 2.



Les règles d'association (plus formellement)

- Soit $I = \{i_1, i_2, \dots, i_n\}$ un ensemble de littéraux appelés **items**.
- Un itemset X : un ensemble d'items $X \subseteq I$
- Une base de données D consiste en un ensemble de transactions T_i t.q. $T_i \subseteq I$
- On dit que T contient X si $X \subseteq T$
- Les items d'une transaction ou d'un itemset sont triés suivant un ordre lexigraphique
- Longueur d'un itemset = nombre d'items qu'il contient
- k -itemset : itemset de longueur k

Définitions

- **Support absolu** d'un itemset X dans D : nombre de transactions qui contiennent X
- **Support relatif** de X dans D : pourcentage de transactions de D qui contiennent X
- **Itemset fréquent** X dans D : itemset X avec un support $\geq \text{minsup}$
- **Règle d'association** : règle de la forme $X \rightarrow Y$ avec
 - $X \subseteq I$,
 - $Y \subseteq I$,
 - $X \cap Y = \emptyset$

Définitions

- Support d'une règle d'association $X \rightarrow Y$ dans D :
 - support de $X \cup Y$ dans D
$$s = \frac{|\{T \in D \mid (X \cup Y) \subseteq T\}|}{|D|}$$
- Confiance d'une règle d'association $X \rightarrow Y$ dans D :
 - pourcentage de transactions contenant Y qui contiennent aussi X
$$c = \frac{|\{T \in D \mid X \cup Y \subseteq T\}|}{|\{T \in D \mid X \subseteq T\}|}$$
- Objectif : Etant donné un seuil de support minsup et un seuil de confiance minconf , découvrir toutes les règles d'association qui ont un support $\geq \text{minsup}$ et une confiance $\geq \text{minconf}$

Exemple

TransactionID	Items
2000	A,B,C
1000	A,C
4000	A,D
5000	B,E,F

$minsup = 50\%$,
 $minconf = 50\%$

Support

(A): 75%, (B), (C): 50%, (D), (E), (F): 25%,

(A, C): 50%, (A, B), (A, D), (B, C), (B, E), (B, F), (E, F): 25%

Règles d'association

$A \Rightarrow C$ (support = 50%, confidence = 66.6%)

$C \Rightarrow A$ (support = 50%, confidence = 100%)

Découverte des règles d'association

- Deux étapes :
 - Découvrir tous les itemsets fréquents dans D
 - Générer les règles d'association à partir des itemsets fréquents :
 - Pour tous les itemsets fréquents X :
 - Pour tous les $A \subset X$: (qui satisfait la contrainte de support)
 - Générer la règle $A \Rightarrow (X - A)$ (qui satisfait la contrainte de support)
 - Vérifier la confiance de la règle


Extraction des motifs fréquents (approche naïve)

- Générer tous les itemsets possibles, puis calculer leur support dans la base de données
- Problèmes :
 - Comment garder en mémoire un nombre important d'itemsets ?
 - 100 items => $2^{100} - 1$ itemsets possibles !!!
 - Comment calculer le support d'un nombre important d'itemsets dans une grande base de données (100 million de transactions) ?

Extraction des motifs fréquents (approche naïve)

- Générer tous les itemsets possibles, puis calculer leur support dans la base de données
- Problèmes :
 - Comment garder en mémoire un nombre important
• 100 items => $2^{100} - 1$ itemsets possibles !!!
 - Comment calculer le support d'un nombre important d'itemsets dans une grande base de données (100 million de transactions) ?

Approche naïve
non viable !!!



Extraction des motifs fréquents

- Propriété d' anti-monotonie du support :
 - Tous les sous ensembles d'un itemset fréquent sont fréquents
 - Si un itemset X n'est pas fréquent alors il n'existe pas d'itemset Y t.q $X \subseteq Y$ qui soit fréquent

Méthode

- Trouver les 1-itemsets fréquents, puis trouver les 2-itemsets fréquents
- Pour trouver les $k+1$ -itemsets fréquents :
 - Seulement considérer les $k+1$ -itemsets t.q. :
 - tous les k -sous-ensembles sont fréquents.
- Calcul du support :
 - Une passe sur la base de données pour compter le support de tous les itemsets pertinents.

Algorithme Apriori

C_k : set of *candidate* item sets of length k

L_k : set of all *frequent* item sets of length k

```
Apriori( $D$ ,  $minsup$ )
 $L_1 := \{\text{frequent 1-item sets in } D\};$ 
 $k := 2;$ 
while  $L_{k-1} \neq \emptyset$  do
     $C_k := \text{AprioriCandidateGeneration}(L_{k-1});$ 
    for each transaction  $T \in D$  do
         $CT := \text{subset}(C_k, T);$  // all candidates from  $C_k$ , that are
                                // contained in transaction  $T$ ;
        for each candidate  $c \in CT$  do  $c.\text{count}++;$ 
     $L_k := \{c \in C_k \mid (c.\text{count} / |D|) \geq minsup\};$ 
     $k++;$ 
return  $\bigcup_k L_k;$ 
```


Génération de candidats

- Propriétés de l'ensemble C_k des k-itemsets candidats
 - Sur-ensemble de L_k
 - Significativement plus petit que tous k-itemsets possibles de I

Génération de candidats : la jointure

- Etape 1:

- p et q : (k-1) itemsets fréquents
- p et q sont joints si ils ont leurs (k-2) premières valeurs identiques
- Ex. :



L₃

Génération de candidats : élagage

- Etape 2 : l'élagage
 - Supprimer tous les éléments de C_k qui ont un $(k-1)$ sous-ensemble qui n'appartient pas à L_{k-1} .
- Ex. : $L_3 = \{(1\ 2\ 3), (1\ 2\ 4), (1\ 3\ 4), (1\ 3\ 5), (2\ 3\ 4)\}$

Jointure : $C_4 = \{(1\ 2\ 3\ 4), (1\ 3\ 4\ 5)\}$

Elagage: suppression de $(1\ 3\ 4\ 5)$ car $(3\ 4\ 5)$ n'appartient pas à L_3

Au final : $C_4 = \{(1\ 2\ 3\ 4)\}$

Exemple d'une extraction complète

Au tableau avec un
treillis et tout l'espace
de recherche.

Exemple d'une extraction complète

$\text{minsup} = 2$

TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

Au tableau avec un treillis et tout l'espace de recherche.

Exemple d'une extraction complète

$\text{minsup} = 2$

TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

Scan D

C_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

Au tableau avec un treillis et tout l'espace de recherche.

Exemple d'une extraction complète

$\text{minsup} = 2$

TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

Scan D

C_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

L_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{5}	3

Au tableau avec un treillis et tout l'espace de recherche.

Exemple d'une extraction complète

$\text{minsup} = 2$

TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

Scan D

C_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

L_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{5}	3

C_2

itemset
{1 2}
{1 3}
{1 5}
{2 3}
{2 5}
{3 5}

Au tableau avec un treillis et tout l'espace de recherche.

Exemple d'une extraction complète

$\text{minsup} = 2$

TID	Items
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

Scan D

C_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

L_1

itemset	sup.
{1}	2
{2}	3
{3}	3
{5}	3

C_2

itemset	sup
{1 2}	1
{1 3}	2
{1 5}	1
{2 3}	2
{2 5}	3
{3 5}	2


C_2

itemset
{1 2}
{1 3}
{1 5}
{2 3}
{2 5}
{3 5}

Scan D


Au tableau avec un treillis et tout l'espace de recherche.

Exemple d'une extraction complète




Au tableau avec un treillis et tout l'espace de recherche.

Exemple d'une extraction complète



Exemple d'une extraction complète



Espace de recherche (suite au tableau)

12345

1234 1235 1245 2345

123 124 125 234 235 345

12 13 14 15 23 24 25 34 35 45

1 2 3 4 5

\emptyset

Calcul du support efficace

- Subset (C_k, T)


Tous les candidats de C_k qui sont contenus dans la transaction T

- Problèmes :

- Très grand nombres d'itemsets candidats
- Une transaction peut contenir un très grand nombre de candidats

- Structure de données Hash tree pour stocker C_k

structure de tous les 3-candidats possibles pour 5 items




Génération des règles à partir des itemsets

- Pseudo-code :
 - Pour chaque itemset fréquent I :
 - Générer tous les sous-ensembles non vides X de I
 - Pour chaque X de I :
 - Si $\text{support}(I)/\text{support}(X) \geq \text{minconf}$ alors
 - produire la règle $X \Rightarrow (I-X)$


Exercice


- Voir feuille de «TD»
 - Extraction de motifs fréquents
 - Propriétés d'Apriori
 - Bordures
- Règles d'association
 - Propriétés
- ...

Visualisation des règles : dans un plan



Graphe de règles






Différentes mesures

symbol	measure	range	formula
ϕ	ϕ -coefficient	-1 ... 1	$\frac{P(A,B) - P(A)P(B)}{\sqrt{P(A)P(B)(1-P(A))(1-P(B))}}$
Q	Yule's Q	-1 ... 1	$\frac{P(A,B)P(\bar{A},\bar{B}) - P(A,\bar{B})P(\bar{A},B)}{P(A,B)P(\bar{A},\bar{B}) + P(A,\bar{B})P(\bar{A},B)}$
Y	Yule's Y	-1 ... 1	$\frac{\sqrt{P(A,B)P(\bar{A},\bar{B})} - \sqrt{P(A,\bar{B})P(\bar{A},B)}}{\sqrt{P(A,B)P(\bar{A},\bar{B})} + \sqrt{P(A,\bar{B})P(\bar{A},B)}}$
k	Cohen's	-1 ... 1	$\frac{P(A,B) + P(\bar{A},\bar{B}) - P(A)P(B) - P(\bar{A})P(\bar{B})}{1 - P(A)P(B) - P(\bar{A})P(\bar{B})}$
PS	Piatetsky-Shapiro's	-0.25 ... 0.25	$P(A,B) - P(A)P(B)$
F	Certainty factor	-1 ... 1	$\max\left(\frac{P(B A) - P(B)}{1 - P(B)}, \frac{P(A B) - P(A)}{1 - P(A)}\right)$
AV	added value	-0.5 ... 1	$\max(P(B A) - P(B), P(A B) - P(A))$
K	Klosgen's Q	-0.33 ... 0.38	$\frac{\sqrt{P(A,B)} \max(P(B A) - P(B), P(A B) - P(A))}{\sum_i \max_k P(A_j, B_k) + \sum_k \max_j P(A_j, B_k) - \max_j P(A_j) - \max_k P(B_k)}$
g	Goodman-kruskal's	0 ... 1	$\frac{2 - \max_j P(A_j) - \max_k P(B_k)}{\sum_i \sum_j P(A_i, B_j) \log \frac{P(A_i, B_j)}{P(A_i)P(B_j)}}$
M	Mutual Information	0 ... 1	$\frac{\min(-\sum_i P(A_i) \log P(A_i) \log P(A_i), -\sum_i P(B_i) \log P(B_i) \log P(B_i))}{\sum_i P(A_i) \log(\frac{P(B A)}{P(B)}) + P(\bar{A}B) \log(\frac{P(\bar{B} A)}{P(B)})}$
J	J-Measure	0 ... 1	$\frac{P(A, B) \log(\frac{P(A B)}{P(A)}) + P(\bar{A}B) \log(\frac{P(\bar{A} B)}{P(A)})}{P(A, B) \log(\frac{P(B A)}{P(B)}) + P(\bar{A}B) \log(\frac{P(\bar{B} A)}{P(B)})}$
G	Gini index	0 ... 1	$\max(P(A)[P(B A)^2 + P(\bar{B} A)^2] + P(\bar{A})[P(B \bar{A})^2 + P(\bar{B} \bar{A})^2] - P(B)^2 - P(\bar{B})^2, P(B)[P(A B)^2 + P(\bar{A} B)^2] + P(\bar{B})[P(A \bar{B})^2 + P(\bar{A} \bar{B})^2] - P(A)^2 - P(\bar{A})^2)$
s	support	0 ... 1	$P(A, B)$
c	confidence	0 ... 1	$\max(P(B A), P(A B))$
L	Laplace	0 ... 1	$\max\left(\frac{NP(A,B)+1}{NP(A)+2}, \frac{NP(A,B)+1}{NP(B)+2}\right)$
IS	Cosine	0 ... 1	$\frac{P(A,B)}{\sqrt{P(A)P(B)}}$
γ	coherence(Jaccard)	0 ... 1	$\frac{P(A,B)}{P(A) + P(B) - P(A,B)}$
α	all_confidence	0 ... 1	$\frac{P(A,B)}{\max(P(A), P(B))}$
o	odds ratio	0 ... ∞	$\frac{P(A,B)P(\bar{A},\bar{B})}{P(\bar{A},B)P(A,\bar{B})}$
V	Conviction	0.5 ... ∞	$\max\left(\frac{P(A)P(\bar{B})}{P(A\bar{B})}, \frac{P(B)P(\bar{A})}{P(B\bar{A})}\right)$
λ	lift	0 ... ∞	$\frac{P(A,B)}{P(A)P(B)}$
S	Collective strength	0 ... ∞	$\frac{P(A,B) + P(\bar{A}\bar{B})}{P(A)P(B) + P(\bar{A})P(\bar{B})} \times \frac{1 - P(A)P(B) - P(\bar{A})P(\bar{B})}{1 - P(A,B) - P(\bar{A}\bar{B})}$
χ^2	χ^2	0 ... ∞	$\sum_i \frac{(P(A_i) - E_i)^2}{E_i}$

Règles d'association multi-niveaux

- Dans de nombreuses applications, des **hiérarchies** sont associées aux items.



- Recherche des R.A sur les feuilles : support risque d'être trop bas.
- Recherche des R.A aux niveaux supérieurs : motifs risquent de représenter des informations déjà connues.
- **Il faut donc chercher des R.A sur tous les niveaux.**

Exemple

Anorak	\Rightarrow Hiking boots	Support < minsup
Windcheater	\Rightarrow Hiking boots	
Jacket	\Rightarrow Hiking boots	Support > minsup

Propriétés :

- Support (Jacket \Rightarrow Hiking boots) peut être différent de support(Anorak \Rightarrow Hiking boots) + support(Windcheater \Rightarrow Hiking boots)
- Si support(Jacket \Rightarrow Hiking boots) $>$ minsup, alors support(Outerwear \Rightarrow Hiking boots) $>$ minsup

Règles d'association multi-niveaux [Agrawal et Srikant, 1995]

- $I = \{i_1, \dots, i_m\}$ un ensemble de littéraux (items)
- H un graphe orienté sans cycle (DAG) sur I
- Dans H , une arête de i vers j si :
 - i est une généralisation de j ,
 - i est le père (prédécesseur direct) de j , j est un fils ou successeur direct
- Plus généralement, \overline{X} prédécesseur de X s'il existe un chemin entre X et X dans H
- itemset \overline{Z} est un prédécesseur d'un itemset Z : pour tout item de Z , on a au moins un pred dans \overline{Z}

-
- D est un ensemble de transactions T où $T \subseteq I$
 - Généralement, une transaction de D contient uniquement des items qui sont **feuilles** dans H
 - Une transaction T supporte un item i si :
 - $i \in T$ ou i est un prédécesseur d'un item j de T
 - T supporte un itemset X si tous les items de I sont supportés par T
 - ex. : (coca, chips) supporte (soda, chips)
 - $\text{Support}(X, D) = \% \text{ de transaction de } D \text{ supportant } X$

-
- Règle d'association multi-niveaux :
 - $X \Rightarrow Y$ où $X \subseteq I$, $Y \subseteq I$, $X \cap Y = \emptyset$ et aucun item de Y n'est prédecesseur d'un item de X dans H ;
 - $\text{Support}(X \Rightarrow Y, D) = \text{support}(X \cup Y, D)$
 - Confiance

Exemple

TransactionID	Items
1	Anorak
2	Windcheater, Hiking boot
3	Anorak, Hiking boot
4	Walking-shoes
5	Walking-shoes
6	Windcheater

- Support(**Jackets**): $4/6 = 67\%$
- Support(**Jackets**, Hiking boots): $2/6 = 33\%$
- Hiking-boots \Rightarrow **Jackets** : Support 33%, Confiance 100%
- **Jackets** \Rightarrow Hiking-boots : Support 33%, Confiance 50%

Déterminer les itemsets fréquents

- Idée originale (algorithme basique) :
 - Etendre la base de données avec tous les prédecesseurs des items contenus dans chaque transaction;
 - ex: T1: (coca,vin) =>T1' :(coca,soda,vin, alcool, boissons ...)
 - Ne pas insérer de duplications !
- Ensuite, rechercher les itemsets fréquents (APriori);
- Optimisations : filtrage des prédecesseurs à ajouter, matérialisation des prédecesseurs.

-
- Suppression des itemsets redondants
 - Soit X un k -itemset, i un item et i' un prédécesseur de i .
 - $X = (i, i', \dots)$
 - Support de $X - \{i'\}$ = support de X
 - X ne doit pas être considérer pendant la génération de candidats
 - On n'a pas besoin de compter le support d'un k -itemset qui contient l'item i et son prédécesseur i'
 - Algorithme *Cumulate*

Stratification

- Alternative à Apriori
- former des couches dans l'ensemble de candidats
- Propriété : si un itemset \bar{X} n'est pas fréquent alors X non plus.
- Méthode :
 - Ne pas compter le support tous les k-itemsets en même temps
 - Compter en premier le support des itemsets les plus généraux et ensuite considérer le calcul des plus spécifiques si nécessaire.

Exemple

- $C_k = \{(Clothes\ Shoes), (Outerwear\ Shoes), (Jackets\ Shoes)\}$
- regarder d'abord (Clothes Shoes)
- compter ensuite le support de (Outerwear Shoes) uniquement si nécessaire

Notations

- *Depth* d'un itemset
- (C_k^n) : Set of item sets from C_k with depth n , $0 \leq n \leq$ maximal depth t

Algorithme Stratify

- Au tableau à partir d'un exemple simple.
- Représentation de l'espace de recherche («treillis déformé»)

Intérêt des règles d'association multi-niveaux

- $X \Rightarrow Y$ est un prédécesseur de $\bar{X} \Rightarrow \bar{Y}$
- Une règle d'association multi-niveaux est R-intéressante si :
 - Elle n'a pas de prédécesseur direct ou
 - Support (ou confiance) est R fois supérieur au support (confiance) attendue et que le prédécesseur direct est aussi R-intéressant.

Exemple

Item	Support
Clothes	20
Outerwear	10
Jackets	4


$$R = 2$$

- Rule-No Rule Support R-interesting ?

- 1 Clothes \Rightarrow Shoes 10 yes, no predecessor
- 2 Outerwear \Rightarrow Shoes 9 yes, support $\approx R * \text{expected support}$ (w.r.t. rule 1)
- 3 Jackets \Rightarrow Shoes 4 no, support $< R * \text{expected support}$ (w.r.t. rule 2)


Choix du support

Fix support



minsup = 5 %

Variable support



minsup = 5 %

minsup = 3 %

Discussion

- Support fixe (même minsup pour tous les niveaux de H)
 - + : efficacité (suppression des successeurs non fréquents)
 - - : réduit l'intérêt des règles
 - minsup trop haut : pas de règles de bas niveau
 - minsup trop bas : trop de règles de haut niveau
- Support variable :
 - + : Intérêt : on trouve des règles aux niveaux appropriés
 - - : efficacité de l'extraction (pas de pruning des successeurs directs)


Règles multidimensionnelles

- Règle mono-dimensionnelle :
 - $\text{buys}(X, \text{"milk"}) \Rightarrow \text{buys}(X, \text{"bread"})$
- Règle multidimensionnelle : ≥ 2 dimensions ou prédictats
 - RA Inter-dimension (pas de prédictats répétés)
 - $\text{age}(X, \text{"19-25"}) \wedge \text{occupation}(X, \text{"student"}) \Rightarrow \text{buys}(X, \text{"coke"})$
 - RA hybrides (prédictats répétés)
 - $\text{age}(X, \text{"19-25"}) \wedge \text{buys}(X, \text{"popcorn"}) \Rightarrow \text{buys}(X, \text{"coke"})$
- Attributs catégoriels : Nombre finis de valeurs possibles, pas d'ordres parmi les valeurs — approche cube de données
- Attributs quantitatifs : Numérique, ordre implicite parmi les valeurs — discrétilisation, clustering, ...

Autres applications de la recherche de motifs ensemblistes : les icebergs


Représenter que les cellules respectant une condition

```
SELECT A,B,C, Count(*),SUM(X)  
FROM TableName  
CUBE BY A,B,C  
HAVING COUNT(*) ≥ minsup
```



Amélioration de l'algorithme Apriori


Rappel



Les enjeux et les idées à développer


- Multiples passages sur la base de données
- Ensemble de candidats très importants
- Calcul du support d'un motif
- Réduire le nombre de passages sur la base de données
- Réduire le nombre de candidats
- Faciliter le calcul du support

DIC : réduction du nombre de passage



S. Brin R. Motwani, J. Ullman,
and S. Tsur, SIGMOD'97.
DIC: Dynamic Itemset Counting

- Dès que A et D sont déterminés comme fréquents, on peut commencer à calculer le support de (AD)
- Dès que les 2-sous-ensembles de (BCD) sont trouvés fréquents alors on peut commencer à chercher le support de (BCD)



DHP : Réduction du nombre de candidats

- A hashing bucket count < min_sup, every candidate in the bucket is infrequent
 - Candidats: a, b, c, d, e
 - Hash entrées: {ab, ad, ae} {bd, be, de}
 - Large 1-itemset: a, b, d, e
 - La somme des supports de {ab, ad, ae} < min_sup
 - inutile de générer (ab)
- J. Park, M. Chen, and P. Yu, SIGMOD'95 – DHP: Direct Hashing and Pruning

Echantillonnage

- Choisir un échantillon et extraire des motifs fréquents à l'aide d'Apriori
- Un passage sur la BD pour vérifier les itemsets fréquents :
 - Seulement la bordure des itemsets fréquents est vérifiée
 - exemple : verif. abcd au lieu de abc, ab, bc,
- Un autre passage pour trouver les motifs qui manquent

Eclat/MaxEclat et VIPER

- Tid-list: la liste des transactions contenant un itemset
 - représentation verticale
- Opération principale : intersection des tid-lists
 - A : t1,t2,t3
 - B ; t2,t3
 - support de (AB) =2

FP-Growth

- Pas de génération de candidats
- Bases de données projetées
- Nous verrons ce concept de façon plus étendue avec l'algorithme prefixSpan d'extraction de motifs séquentiels

Fouille de motifs fréquents sous contraintes

Motivations

- Trouver tous les motifs qui apparaissent dans une base de données
 - Risque d'être trop nombreux et pas être intéressant
- La fouille de données doit être interactive
 - l'utilisateur exprime ce qui doit être extrait
- Fouille de motifs sous contraintes
 - Flexibilité pour l'utilisateur : modélise son intérêt
 - Optimisation : pousser des contraintes pour une fouille plus efficace

Contraintes en fouille de motifs

- Contraintes sur les données - requêtes SQL
 - trouver les produits vendus ensemble dans les magasins de N.Y.
- Contraintes sur les niveaux/dimensions
 - région, prix, marque, catégories de consommateurs
- Contraintes sur les motifs ou règles
 - les petits achats (<10\$) qui provoquent de gros achats (>100\$)
- Contraintes sur l'intérêt : (support, confiance, ...)

Extraction de motifs sous contraintes

- Solution naïve : post-traitement
- Approches plus efficaces :
 - Analyser les propriétés des contraintes
 - «pousser» des contraintes en même temps que la fouille des motifs fréquents.

Anti-monotonie

- Si un motif X viole une contrainte, alors tous ses super-motifs aussi.

TDB ($\text{min_sup}=2$)

- $\sum(X.\text{Price}) \leq v$: antimonotone
- $\sum(X.\text{Price}) > v$: non antimonotone
- Exemple :

TID	Transaction
10	a, b, c, d, f
20	b, c, d, f, g, h
30	a, c, d, e, f
40	c, e, f, g

- C: $\text{range}(S.\text{profit}) \leq 15$
- itemset (ab) viole C
- comme tous les sur-ensemble de (ab)

Item	Profit
a	40
b	0
c	-20
d	10
e	-30
f	30
g	20

Contraintes anti-monotone

Constraint	Antimonotone
$v \in S$	No
$S \supseteq V$	no
$S \subseteq V$	yes
$\min(S) \leq v$	no
$\min(S) \geq v$	yes
$\max(S) \leq v$	yes
$\max(S) \geq v$	no
$\text{count}(S) \leq v$	yes
$\text{count}(S) \geq v$	no
$\text{sum}(S) \leq v \ (a \in S, a \geq 0)$	yes
$\text{sum}(S) \geq v \ (a \in S, a \geq 0)$	no
$\text{range}(S) \leq v$	yes
$\text{range}(S) \geq v$	no
$\text{avg}(S) \theta v, \theta \in \{=, \leq, \geq\}$	convertible
$\text{support}(S) \geq \xi$	yes
$\text{support}(S) \leq \xi$	no

Contraintes monotones

- X satisfait la contrainte C alors tous ses super motifs aussi.
 - $\text{sum}(X.\text{Price}) > v$ (monotone)

Contraintes monotones

Constraint	Monotone
$v \in S$	yes
$S \supseteq V$	yes
$S \subseteq V$	no
$\min(S) \leq v$	yes
$\min(S) \geq v$	no
$\max(S) \leq v$	no
$\max(S) \geq v$	yes
$\text{count}(S) \leq v$	no
$\text{count}(S) \geq v$	yes
$\text{sum}(S) \leq v \text{ (} a \in S, a \geq 0 \text{)}$	no
$\text{sum}(S) \geq v \text{ (} a \in S, a \geq 0 \text{)}$	yes
$\text{range}(S) \leq v$	no
$\text{range}(S) \geq v$	yes
$\text{avg}(S) \theta v, \theta \in \{ =, \leq, \geq \}$	convertible
$\text{support}(S) \geq \xi$	no
$\text{support}(S) \leq \xi$	yes

Contraintes succinctes

- La vérification qu'itemset X satisfasse une contrainte C peut se faire sans regarder les transactions.
 - $\min(X.\text{price}) > v$ (succinct)
 - $\sum(X.\text{price}) > v$ (non-succinct)

contraintes succinctes

Constraint	Succinct
$v \in S$	yes
$S \supseteq V$	yes
$S \subseteq V$	yes
$\min(S) \leq v$	yes
$\min(S) \geq v$	yes
$\max(S) \leq v$	yes
$\max(S) \geq v$	yes
$\text{count}(S) \leq v$	weakly
$\text{count}(S) \geq v$	weakly
$\sum(S) \leq v \ (a \in S, a \geq 0)$	no
$\sum(S) \geq v \ (a \in S, a \geq 0)$	no
$\text{range}(S) \leq v$	no
$\text{range}(S) \geq v$	no
$\text{avg}(S) \theta v, \theta \in \{=, \leq, \geq\}$	no
$\text{support}(S) \geq \xi$	no
$\text{support}(S) \leq \xi$	no

Contraintes convertibles

- Convertir une contrainte en une contrainte monotone ou anti-monotone en redéfinissant un ordre sur les items.

- ex : C:avg(S.profit)≥25

- Ordonné les items en par leur prix (décroissant)

TDB (min_sup=2)	
TID	Transaction
10	a, b, c, d, f
20	b, c, d, f, g, h
30	a, c, d, e, f
40	c, e, f, g

Item	Profit
a	40
b	0
c	-20
d	10
e	-30
f	30
g	20
h	-10

- <a,f,g,d,b,h,c,e>


- si (afb) viole C

- (afb*) aussi

Introduction aux représentations condensées

Fouille de séquences (voir .pdf)

Fouille de motifs fréquents :



Clustering (regroupement, segmentation)

Différentes techniques de clustering

Problématique


- Soient N instances de données à K attributs
- Trouver un partitionnement en c clusters (groupes) ayant du sens.
- Affectation automatique de «labels» aux clusters
- c peut être donné ou recherché
- Les classes ne sont pas connues à l'avance (non supervisé)
- Attributs de différents types

Qualité d'un clustering

- Une bonne méthode de regroupement permet de garantir
 - Une **grande similarité intra-groupe**
 - Une **faible similarité inter-groupe**
- La qualité d'un regroupement dépend donc de la **mesure de similarité** utilisée par la méthode et de son implémentation
- La **qualité d'une méthode** de clustering est évaluée par son capacité à découvrir certains ou tous les “patterns” cachés.

Objectif du clustering

- **Minimiser les distances intra-clusters**
- **Maximiser les distances inter-clusters**



Exemples d'applications

Marketing : segmentation du marché en découvrant des groupes de clients distincts à partir de bases de données d'achats.

- **Environnement** : identification des zones terrestres similaires (en termes d'utilisation) dans une base de données d'observation de la terre.
- **Assurance** : identification de groupes d'assurés distincts associés à un nombre important de déclarations.
- **Planification de villes** : identification de groupes d'habitations suivant le type d'habitation, valeur, localisation géographique, ...
- **Médecine** : Localisation de tumeurs dans le cerveau „ Nuage de points du cerveau fournis par le neurologue „ Identification des points définissant une tumeur :

Mesure de la similarité

- Pas de définition unique de la similarité entre objets
 - différentes mesures de distance $d(x,y)$
- La définition de la similarité entre objets dépend de :
 - Le type de données considérées
 - Le type de similarité recherchée

Choix de la distance

- Propriété d'une distance :
 - $d(x,y) \geq 0$
 - $d(x,y) = 0$ ssi $x=y$
 - $d(x,y) = d(y,x)$
 - $d(x,z) \leq d(x,y) + d(y,z)$
- Définir une distance sur chacun des champs
- ex (numérique, e.g., âge, poids, taille, etc.): $d(x,y) = |x-y|$; $d(x,y) = |x-y|/\text{dmax}$ (dist. normalisée)

Types des variables

- Intervalles:
- Binaires:
- catégories, ordinales, ratio:
- Différents types:

Intervalle (discrètes)

- Standardiser les données
- Calculer l'écart absolu moyen:

$$s_f = \frac{1}{n}(|x_{1f} - m_f| + |x_{2f} - m_f| + \dots + |x_{nf} - m_f|)$$

- où

$$m_f = \frac{1}{n}(x_{1f} + x_{2f} + \dots + x_{nf}).$$

- Calculer la mesure standardisée (z-score)


$$z_{if} = \frac{x_{if} - m_f}{s_f}$$

Exemple

	Age	Salaire
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

$$M_{Age} = 60 \quad S_{Age} = 5$$

$$M_{salaire} = 11074 \quad S_{salaire} = 148$$



	Age	Salaire
Personne1	-2	-0,5
Personne2	2	0,175
Personne3	0	0,324
Personne4	0	2

Similarité entre objets

Les distances expriment une similarité

Ex: la distance de Minkowski :

$$d(i, j) = \sqrt[q]{(|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \dots + |x_{ip} - x_{jp}|^q)}$$

où $i = (x_{i1}, x_{i2}, \dots, x_{ip})$ et $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ sont deux objets p-dimensionnels et q un entier positif

Si $q = 1$, d est la distance de Manhattan

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots + |x_{ip} - x_{jp}|$$

Similarité entre objets(I)

Si $q = 2$, d est la distance Euclidienne :

$$d(i, j) = \sqrt{(|x_{i_1} - x_{j_1}|^2 + |x_{i_2} - x_{j_2}|^2 + \dots + |x_{i_p} - x_{j_p}|^2)}$$

Propriétés

$$d(i, j) \geq 0$$

$$d(i, i) = 0$$

$$d(i, j) = d(j, i)$$

$$d(i, j) \leq d(i, k) + d(k, j)$$

Exemple: distance de Manhattan

	Age	Salaire
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

Exemple: distance de Manhattan

	Age	Salaire
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

$$d(p1, p2) = 120$$

$$d(p1, p3) = 132$$

Exemple: distance de Manhattan

	Age	Salaire
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

$$d(p1, p2) = 120$$

$$d(p1, p3) = 132$$

Conclusion: p1 ressemble plus à p2 qu'à p3!!! :-(

Exemple: distance de Manhattan

	Age	Salairé
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

$$d(p1, p2) = 120$$

$$d(p1, p3) = 132$$

Conclusion: p1 ressemble plus à p2 qu'à p3!!! :-(

	Age	Salairé
Personne1	-2	-0,5
Personne2	2	0,175
Personne3	0	0,324
Personne4	0	0

Exemple: distance de Manhattan

	Age	Salairé
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

$$d(p1, p2) = 120$$

$$d(p1, p3) = 132$$

Conclusion: p1 ressemble plus à p2 qu'à p3!!! :-(

	Age	Salairé
Personne1	-2	-0,5
Personne2	2	0,175
Personne3	0	0,324
Personne4	0	0

$$d(p1, p2) = 4,675$$

$$d(p1, p3) = 2,324$$

Exemple: distance de Manhattan

	Age	Salairé
Personne1	50	11000
Personne2	70	11100
Personne3	60	11122
Personne4	60	11074

$$d(p1, p2) = 120$$

$$d(p1, p3) = 132$$

Conclusion: p1 ressemble plus à p2 qu'à p3!!! :-)

	Age	Salairé
Personne1	-2	-0,5
Personne2	2	0,175
Personne3	0	0,324
Personne4	0	0

$$d(p1, p2) = 4,675$$

$$d(p1, p3) = 2,324$$

Conclusion: p1 ressemble plus à p3 qu'à p2 !!! :-)

Variables binaires

- Une table de contingence pour données binaires

		Objet <i>j</i>		<i>sum</i>
		1	0	
<i>Objet i</i>	1	<i>a</i>	<i>b</i>	<i>a+b</i>
	0	<i>c</i>	<i>d</i>	<i>c+d</i>
<i>sum</i>		<i>a+c</i>	<i>b+d</i>	<i>p</i>

a= nombre de positions
où *i* a 1 et *j* a 1

- Exemple $\mathbf{o_i}=(1,1,0,1,0)$ et $\mathbf{o_j}=(1,0,0,0,1)$

- $a=1$, $b=2$, $c=1$, $d=2$

Mesures de distances

- Coefficient d'appariement (matching) simple (invariant pour variables symétriques):

$$d(i, j) = \frac{b + c}{a + b + c + d}$$

- Exemple $o_i = (1, 1, 0, 1, 0)$ et $o_j = (1, 0, 0, 0, 1)$

- $d(o_i, o_j) = 3/5$

- Coefficient de Jaccard

- $d(o_i, o_j) = 3/4$

$$d(i, j) = \frac{b + c}{a + b + c}$$

Variables binaires (I)

- Variable symétrique: Ex. le sexe d'une personne, i.e coder masculin par 1 et féminin par 0 c'est pareil que le codage inverse
- Variable asymétrique: Ex. Test HIV. Le test peut être positif ou négatif (0 ou 1) mais il y a une valeur qui sera plus présente que l'autre. Généralement, on code par 1 la modalité la moins fréquente
 - 2 personnes ayant la valeur 1 pour le test sont plus similaires que 2 personnes ayant 0 pour le test

Variables binaires(II)

- Exemple

Nom	Sexe	Fièvre	Toux	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

- Sexe est un attribut symétrique
- Les autres attributs sont asymétriques
- Y et P ≡ 1, N ≡ 0, la distance n'est mesurée que sur les asymétriques

$$d(jack, mary) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(jack, jim) = \frac{1 + 1}{1 + 1 + 1} = 0.67$$

$$d(jim, mary) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$

Les plus similaires sont Jack et Mary \Rightarrow atteints du même mal

Variables Nominales

- Une généralisation des variables binaires, ex: rouge, vert et bleu
- Méthode 1: Matching simple
 - m: # d'appariements, p: # total de variables

$$d(i, j) = \frac{p - m}{p}$$

- Méthode 2: utiliser un grand nombre de variables binaires
 - Créer une variable binaire pour chaque modalité (ex: variable rouge qui prend les valeurs vrai ou faux)

Variables Ordinales

- Une variable ordinaire peut être discrète ou continue
- L'ordre peut être important, ex: classement
- Peuvent être traitées comme les variables intervalles
 - remplacer x_{if} par son rang $r_{if} \in \{1, \dots, M_f\}$
 - Remplacer le rang de chaque variable par une valeur dans $[0, 1]$ en remplaçant la variable f dans l'objet l par

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

- Utiliser une distance pour calculer la similarité

En Présence de Variables de différents Types

- Pour chaque type de variables utiliser une mesure adéquate. Problèmes: les clusters obtenus peuvent être différents
- On utilise une formule pondérée pour faire la combinaison

- f est binaire ou nominale: $d(i, j) = \frac{\sum_{f=1}^P \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^P \delta_{ij}^{(f)}}$
 - $d_{ij}^{(f)} = 0$ si $x_{if} = x_{jf}$, sinon $d_{ij}^{(f)} = 1$
- f est de type intervalle: utiliser une distance normalisée
- f est ordinale
 - calculer les rangs r_{if} et
 - ensuite traiter z_{if} comme une variable de type intervalle

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

Approches de Clustering

- Algorithmes de Partitionnement: Construire plusieurs partitions puis les évaluer selon certains critères
- Algorithmes hiérarchiques: Créer une décomposition hiérarchique des objets selon certains critères
- Algorithmes basés sur la densité: basés sur des notions de connectivité et de densité

Méthodes de clustering : caractéristiques

- Extensibilité
- Abilité à traiter différents types de données
- Découverte de clusters de différents formes
- Connaissances requises (paramètres de l'algorithme)
- Abilité à traiter les données bruitées et isolées.

Algorithmes à partitionnement

- Construire une partition à **k** clusters d'une base **D** de **n** objets
- Les **k** clusters doivent optimiser le critère choisi
 - Global optimal: Considérer toutes les **k**-partitions
 - Heuristic methods: Algorithmes k-means et k-medoids
 - k-means (MacQueen'67): Chaque cluster est représenté par son centre
 - k-medoids or PAM (Partition around medoids) (Kaufman & Rousseeuw'87): Chaque cluster est représenté par un de ses objets

La méthode des k-moyennes (K-Means)

- L'algorithme k-means est en 4 étapes :
 1. Choisir k objets formant ainsi k clusters
 2. (Ré)affecter chaque objet O au cluster C_i de centre M_i tel que $\text{dist}(O, M_i)$ est minimal
 3. Recalculer M_i de chaque cluster (le barycentre)
 4. Aller à l'étape 2 si on vient de faire une affectation

K-Means :Exemple

- $A=\{1,2,3,6,7,8,13,15,17\}$. Créer 3 clusters à partir de A
- On prend 3 objets au hasard. Supposons que c'est 1, 2 et 3. Ca donne $C_1=\{1\}$, $M_1=1$, $C_2=\{2\}$, $M_2=2$, $C_3=\{3\}$ et $M_3=3$
- Chaque objet O est affecté au cluster au milieu duquel, O est le plus proche. 6 est affecté à C_3 car $\text{dist}(M_3, 6) < \text{dist}(M_2, 6)$ et $\text{dist}(M_3, 6) < \text{dist}(M_1, 6)$; On a
 - $C_1=\{1\}$, $M_1=1$,
 - $C_2=\{2\}$, $M_2=2$
 - $C_3=\{3, 6, 7, 8, 13, 15, 17\}$, $M_3=69/7=9.86$

K-Means :Exemple (suite)

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$
- $\text{dist}(3, M_1) < \text{dist}(3, M_2) \rightarrow 3$ passe en 1. $\text{dist}(8, M_2) < \text{dist}(8, M_3) \rightarrow 8$ passe en 2

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$
- $\text{dist}(3, M_1) < \text{dist}(3, M_2) \rightarrow 3$ passe en 1. $\text{dist}(8, M_2) < \text{dist}(8, M_3) \rightarrow 8$ passe en 2
- $C_1 = \{1, 2, 3\}$, $M_1 = 2$, $C_2 = \{6, 7, 8\}$, $M_2 = 7$, $C_3 = \{13, 15, 17\}$, $M_3 = 15$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$
- $\text{dist}(3, M_1) < \text{dist}(3, M_2) \rightarrow 3$ passe en 1. $\text{dist}(8, M_2) < \text{dist}(8, M_3) \rightarrow 8$ passe en 2
- $C_1 = \{1, 2, 3\}$, $M_1 = 2$, $C_2 = \{6, 7, 8\}$, $M_2 = 7$, $C_3 = \{13, 15, 17\}$, $M_3 = 15$

K-Means :Exemple (suite)

- $\text{dist}(3, M_2) < \text{dist}(3, M_3) \rightarrow 3$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3\}$, $M_2 = 2.5$, $C_3 = \{6, 7, 8, 13, 15, 17\}$ et $M_3 = 66/6 = 11$
- $\text{dist}(6, M_2) < \text{dist}(6, M_3) \rightarrow 6$ passe dans C_2 . Tous les autres objets ne bougent pas. $C_1 = \{1\}$, $M_1 = 1$, $C_2 = \{2, 3, 6\}$, $M_2 = 11/3 = 3.67$, $C_3 = \{7, 8, 13, 15, 17\}$, $M_3 = 12$
- $\text{dist}(2, M_1) < \text{dist}(2, M_2) \rightarrow 2$ passe en C_1 . $\text{dist}(7, M_2) < \text{dist}(7, M_3) \rightarrow 7$ passe en C_2 . Les autres ne bougent pas. $C_1 = \{1, 2\}$, $M_1 = 1.5$, $C_2 = \{3, 6, 7\}$, $M_2 = 5.34$, $C_3 = \{8, 13, 15, 17\}$, $M_3 = 13.25$
- $\text{dist}(3, M_1) < \text{dist}(3, M_2) \rightarrow 3$ passe en 1. $\text{dist}(8, M_2) < \text{dist}(8, M_3) \rightarrow 8$ passe en 2
- $C_1 = \{1, 2, 3\}$, $M_1 = 2$, $C_2 = \{6, 7, 8\}$, $M_2 = 7$, $C_3 = \{13, 15, 17\}$, $M_3 = 15$
- **Plus rien ne bouge**

Illustration (1)




Illustration (2)





Illustration (3)



Exemple

- 8 points A, ..., H de l'espace euclidien 2D. k=2 (2 groupes)
- Tire aléatoirement 2 centres : B et D choisis.

points	Centre D(2,4), B(2,2)	Centre D(2,4), I(27/7,17/7)	Centre J(5/3,10/3), K(24/5,11/5)
A(1,3)	B	D	J
B(2,2)	B	I	J
C(2,3)	B	D	J
D(2,4)	D	D	J
E(4,2)	B	I	K
F(5,2)	B	I	K
G(6,2)	B	I	K
H(7,3)	B	I	K

Commentaires sur la méthode des K-Means

- Force
 - **Relativement extensible** dans le traitement d'ensembles de taille importante
 - **Relativement efficace** : $O(t.k.n)$, où n représente # objets, k # clusters, et t # iterations. Normalement, k, t << n.
- Faiblesses
 - N'est pas applicable en présence d'attributs où la **moyenne** n'est pas définie
 - On doit spécifier **k** (nombre de clusters)
 - Incapable de traiter des données **bruitées**
 - Les clusters sont construits par rapport à des **objets inexistant**s (les milieux)
 - Ne peut pas découvrir les **groupes non-convexes**
 - Les **outliers** sont mal gérés.

Variantes des K-means

- Sélection des centres initiaux
- Calcul des similarités
- Calcul des centres (K-medoids : [Kaufman & Rousseeuw'87])
- GMM : Variantes de K-moyennes basées sur les probabilités
- K-modes : données catégorielles [Huang'98]
- K-prototype : données mixtes (numériques et catégorielles)

Méthodes hiérarchiques


- **Une méthode hiérarchique** : construit une hiérarchie de clusters, non seulement une partition unique des objets.
- Le nombre de clusters k n'est pas exigé comme donnée
- Utilise une matrice de distances comme critère de clustering
- Une **condition de terminaison** peut être utilisée (ex. Nombre de clusters)

Méthodes hiérarchiques

Entrée : un échantillon de m enregistrements x_1, \dots, x_m

- 1.** On commence avec m clusters (cluster = 1 enregistrement)
- 2.** Grouper les deux clusters les plus « proches ».
- 3.** S'arrêter lorsque tous les enregistrements sont membres d'un seul groupe
- 4.** Aller en 2.

Arbre de clusters



-
- Résultat : Graphe hiérarchique qui peut être coupé à un niveau de dissimilarité pour former une partition.
 - La hiérarchie de clusters est représentée comme un arbre de clusters, appelé **dendrogramme**
 - Les feuilles de l'arbre représentent les objets
 - Les noeuds intermédiaires de l'arbre représentent les clusters

Distances entre clusters


- Distance entre les centres des clusters (Centroid Method)
- Distance minimale entre toutes les paires de données des 2 clusters (Single Link Method) $d(i, j) = \min_{x \in C_i, y \in C_j} \{d(x, y)\}$
- Distance maximale entre toutes les paires de données des 2 clusters (Complete Link Method) $d(i, j) = \max_{x \in C_i, y \in C_j} \{d(x, y)\}$
- Distance moyenne entre toutes la paires d'enregistrements (Average Linkage) $d(i, j) = \text{avg}_{x \in C_i, y \in C_j} \{d(x, y)\}$

+ et -

- Avantages :
 - **Conceptuellement simple**
 - **Propriétés théoriques** sont bien connues
 - Quand les clusters sont groupés, la décision est définitive => le nombre d'alternatives différentes à examiner est réduit
- Inconvénients :
 - **Groupement** de clusters est **définitif** => décisions erronées sont **impossibles à modifier** ultérieurement
 - Méthodes **non extensibles** pour des ensembles de données de grandes tailles


Méthode basée sur la densité

- Pour ce types de problèmes, l'utilisation de mesures de similarité (distance) est moins efficace que l'utilisation de **densité de voisinage**.



Clustering basé sur la densité

- Voit les clusters comme des régions denses séparées par des régions qui le sont moins (bruit)
- Deux paramètres:
 - **Eps**: Rayon maximum du voisinage
 - **MinPts**: Nombre minimum de points dans le voisinage-Eps d'un point
- **Voisinage** : $V_{Eps}(p)$: $\{q \in D \mid \text{dist}(p,q) \leq Eps\}$
- Un point **p** est directement densité-accessible à partir de **q** resp. à **Eps, MinPts** si
 - 1) $p \in V_{Eps}(q)$
 - 2) $|V_{Eps}(q)| \geq \text{MinPts}$




MinPts = 5
Eps = 1 cm

Clustering basé sur la densité


- Accessibilité:

- p est accessible à partir de q resp. à Eps, MinPts si il existe p_1, \dots, p_n , $p_1 = q$, $p_n = p$ t.q p_{i+1} est directement densité accessible à partir de p_i




- Connexité

- p est connecté à q resp. à Eps, MinPts si il existe un point o t.q p et q accessibles à partir de o resp. à Eps et MinPts .



DBSCAN: Density Based Spatial Clustering of Applications with Noise

- Un cluster est l'ensemble maximal de points connectés
- Découvre des clusters non nécessairement convexes



DBSCAN: l'algorithme

- Choisir **p**
- Récupérer tous les points accessibles à partir de **p** resp. **Eps** et **MinPts**.
- Si **p** est un centre, un cluster est formé.
- si **p** est une limite, alors il n'y a pas de points accessibles de **p** : passer à un autre point
- Répéter le processus jusqu'à épuiser tous les points.

Résumé

- Le clustering groupe des objets en se basant sur leurs **similarités**.
- Le clustering possède plusieurs applications.
- La mesure de similarité peut être calculée pour **différents types** de données.
- La sélection de la **mesure de similarité** dépend des données utilisées et le type de similarité recherchée.

-
- Les méthodes de clustering peuvent être classées en :
 - Méthodes de partitionnement,
 - Méthodes hiérarchiques,
 - Méthodes à densité de voisinage
 - Plusieurs travaux de recherche sur le clustering en cours et en perspective.
 - Plusieurs applications en **perspective** : Génomique, Environnement, ...